

Laboratorio 4

Juan sebastián Pinzón Rocancio Santiago Pardo Bravo Daniel Felipe Reyes Ramírez

Link a repositorio en Github:

https://github.com/G12-NeuralLesses-BusinessIntelligence/Lab4

Primer endpoint - Predict:

A continuación veremos los escenarios. Los escenarios variarán entre cada uno en la cantidad de elementos que tienen, en sí en la ejecución es exitosa o fallida, y en qué tan correcta es la predicción dados los valores de entrada de los features.

Los escenarios son conjuntos de tamaño n conformados por elementos tomados de forma aleatoria del dataset original usado en el laboratorio 3 y transformado a formato JSON.

Finalmente, cabe aclarar que la variable a predecir es Admission Points, y aunque claramente el modelo no la tendrá en cuenta para la predicción ya que es la variable a predecir, la dejaremos dentro del JSON ya que el modelo de todas formas la ignorará pero nos servirá para compararla con la predicción que haga el modelo. En un entorno de producción donde no nos importe comparar la entrada con la predicción simplemente podríamos poner un 0 para llenar la columna. Esto lo realizaremos en el Escenario 5 a manera de demostración.

Escenario 1.

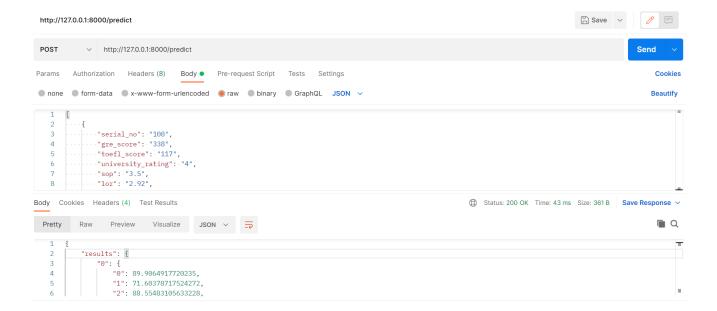
Escenario tomado del dataset original. Los resultados deberían ser lo más correctos posibles y la ejecución no debería dar errores.

Tamaño del conjunto de prueba: 10 elementos

```
,{"serial_no":"298", gre_score":"329", toefl_score":"114", university rating":"3
","sop":"3.28","lor":"4.5","cgpa":"9.24","research":"0","admission_points":"87.9
5"},{"serial_no":"498","gre_score":"280","toefl_score":"72","university_rating":
"5", "sop": "4.5", "lor": "5", "cgpa": "9.56", "research": "1", "admission_points": "93"},
{"serial_no": "300", "gre_score": "305", "toefl_score": "96", "university_rating": "3",
"sop":"4.58","lor":"1.12","cgpa":"8.65","research":"0","admission_points":"71"},
{"serial_no":"255","gre_score":"275","toefl_score":"94","university_rating":"4",
"sop":"4","lor":"5","cgpa":"8.79","research":"0","admission_points":"127.5"},{"s
erial_no":"255","gre_score":"321","toefl_score":"114","university_rating":"4","s
op":"4","lor":"5","cgpa":"9.12","research":"0","admission points":"85"},{"serial
_no":"415","gre_score":"321","toefl_score":"109","university_rating":"4","sop":"
3.5","lor":"4","cgpa":"8.35","research":"1","admission_points":"72"},{"serial_no
":"286","gre_score":"329","toefl_score":"115","university_rating":"5","sop":"4.1
6","lor":"1.67","cgpa":"6.75","research":"1","admission_points":"90.96"},{"seria
l_no":"1", "gre_score":"337", "toefl_score":"118", "university_rating":"4", "sop":"4
.5","lor":"1.63","cgpa":"8.51","research":"1","admission_points":"92"},{"serial_
no":"397", "gre_score": "325", "toefl_score": "84", "university_rating": "3", "sop": "3"
,"lor":"3.5","cgpa":"8.79","research":"1","admission_points":"84"}]
```

Output:

```
{
    "results": {
        "0": {
            "0": 89.9064917720235,
            "1": 71.60378717524272,
            "2": 88.55483105633228,
            "3": 62.21592751757917,
            "4": 68.7296567278773,
            "5": 77.25474114588343,
            "6": 83.07313852410638,
            "7": 81.43827369600024,
            "8": 84.88722042849943,
            "9": 76.350711553958
        }
    }
}
```



Escenario 2.

Escenario tomado del dataset original. Los resultados deberían ser lo más correctos posibles y la ejecución no debería dar errores.

Tamaño del conjunto de prueba: 5 elementos

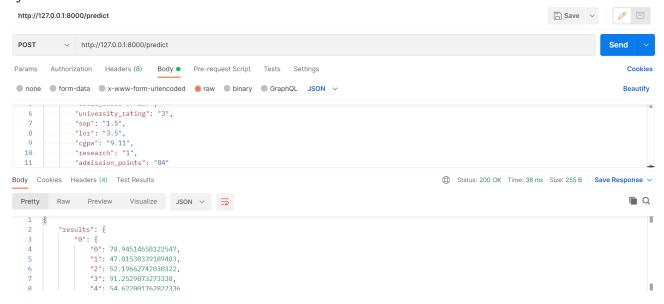
```
[{"serial_no":"397","gre_score":"325","toefl_score":"107","university_rating":"3
","sop":"1.5","lor":"3.5","cgpa":"9.11","research":"1","admission_points":"84"},
{"serial_no":"41","gre_score":"313","toefl_score":"77","university_rating":"1","
sop":"2.79","lor":"3.93","cgpa":"8.08","research":"0","admission_points":"50.63"
},{"serial_no":"40","gre_score":"299","toefl_score":"88","university_rating":"2","sop":"3.33","lor":"3.05","cgpa":"7.92","research":"0","admission_points":"48.5
"},{"serial_no":"338","gre_score":"300","toefl_score":"78","university_rating":"5","sop":"5","lor":"5","cgpa":"9.47","research":"1","admission_points":"94"},{"serial_no":"447","gre_score":"299","toefl_score":"100","university_rating":"2","sop":"2","lor":"2.26","cgpa":"8.55","research":"0","admission_points":"46.52"}]
```

Output:

```
{
    "results": {
        "0": {
            "0": 78.94514658122547,
            "1": 47.81538339189483,
            "2": 52.19662742030322,
            "3": 91.2529873273338,
            "4": 54.622001762822336
```

```
}
}
```

Ejecución en Postman:



Escenario 3.

Escenario tomado del dataset original. Los resultados deberían ser lo más correctos posibles y la ejecución no debería dar errores.

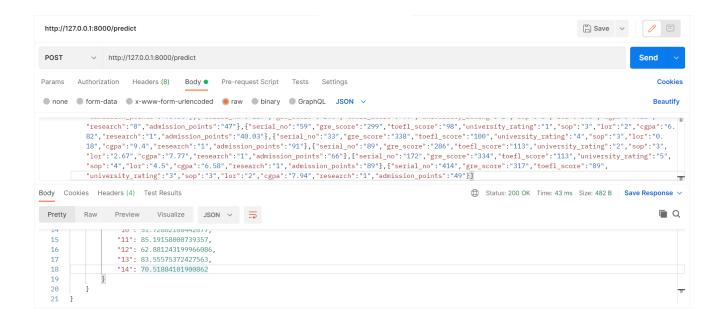
Tamaño del conjunto de prueba: 15 elementos

```
[{"serial_no":"426","gre_score":"323","toefl_score":"111","university_rating":"5
","sop":"2.15","lor":"5","cgpa":"9.86","research":"1","admission_points":"138"},
{"serial_no": "492", "gre_score": "297", "toefl_score": "99", "university_rating": "4",
"sop":"2.86","lor":"1.99","cgpa":"7.81","research":"0","admission_points":"54"},
{"serial no":"288", "gre score":"324", "toefl score":"97", "university rating":"5",
"sop":"4.63","lor":"4.5","cgpa":"9.08","research":"1","admission_points":"89"},{
serial_no":"59","gre_score":"300","toefl_score":"99","university_rating":"1","s"
op":"4.32","lor":"2","cgpa":"6.8","research":"1","admission_points":"36"},{"seri
al_no":"227","gre_score":"306","toefl_score":"110","university_rating":"2","sop"
:"3.5","lor":"4","cgpa":"8.45","research":"0","admission points":"63"},{"serial
no":"95", "gre_score":"302", "toefl_score":"111", "university_rating":"2", "sop":"4.
43","lor":"3","cgpa":"7.71","research":"0","admission_points":"42.44"},{"serial_
no":"186", "gre_score":"327", "toefl_score":"109", "university_rating":"4", "sop":"4
.54","lor":"2.05","cgpa":"9.11","research":"1","admission_points":"89"},{"serial
no":"107", "gre score":"313", "toefl score":"81", "university rating":"3", "sop":"2
.85","lor":"2.71","cgpa":"7.7","research":"0","admission_points":"39.6"},{"seria
```

```
l_no":"35","gre_score":"331","toefl_score":"114","university_rating":"4","sop":"
4.4","lor":"1.35","cgpa":"9.74","research":"0","admission_points":"90.36"},{"ser
ial_no":"119","gre_score":"296","toefl_score":"99","university_rating":"2","sop"
:"3","lor":"3.5","cgpa":"7.28","research":"0","admission_points":"47"},{"serial_
no":"59","gre_score":"299","toefl_score":"98","university_rating":"1","sop":"3",
"lor":"2","cgpa":"6.82","research":"1","admission_points":"40.03"},{"serial_no":
"33","gre_score":"338","toefl_score":"100","university_rating":"4","sop":"3","lo
r":"0.18","cgpa":"9.4","research":"1","admission_points":"91"},{"serial_no":"89"},
"gre_score":"286","toefl_score":"113","university_rating":"2","sop":"3","lor":"
2.67","cgpa":"7.77","research":"1","admission_points":"66"},{"serial_no":"172","
gre_score":"334","toefl_score":"113","university_rating":"5","sop":"4","lor":"4.
5","cgpa":"6.58","research":"1","admission_points":"89"},{"serial_no":"414","gre
_score":"317","toefl_score":"89","university_rating":"3","sop":"3","lor":"2","cg
pa":"7.94","research":"1","admission_points":"49"}]
```

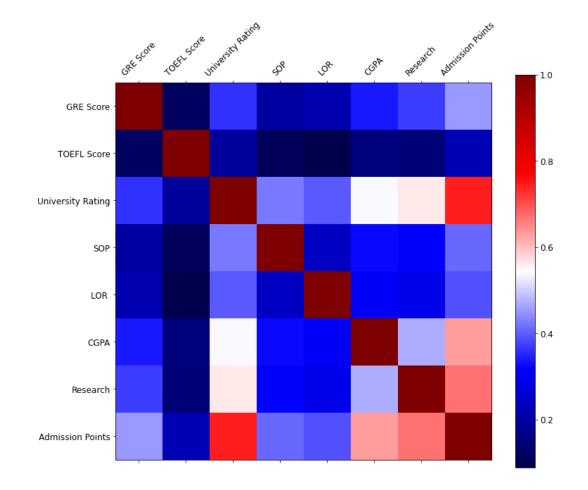
Output:

```
"results": {
    "0": {
        "0": 96.76833860907487.
        "1": 63.48732576439661,
        "2": 93.12867090605667,
        "3": 52.71317084351624,
        "4": 58.465999471439545,
        "5": 54.319720385995495,
        "6": 86.18182812912491,
        "7": 57.630392844469114,
        "8": 78.143577928714,
        "9": 50.05722891160464,
        "10": 51.72802160442677,
        "11": 85.19158000739357,
        "12": 62.881243199966086,
        "13": 83.55575372427563,
        "14": 70.51884101900862
   }
```



Escenario 4.

Según el perfilamiento de datos realizado en el laboratorio 3, pudimos encontrar que las features que mayor correlación tienen con la variable objetivo Admission Points son: Research, CGPA y University Rating.

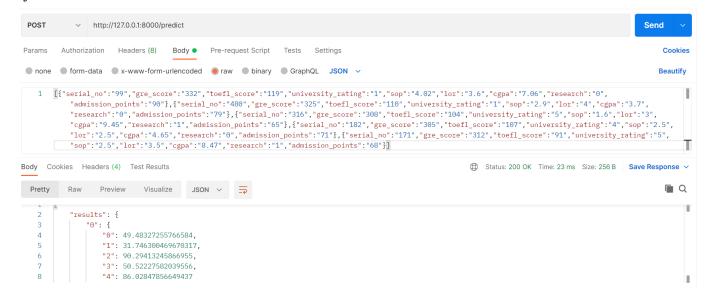


Por lo que, tomaremos del dataset original 5 elementos y cambiaremos los valores de esos features más importantes por valores aleatorios afectando así el resultado.

```
[{"serial_no":"99","gre_score":"332","toefl_score":"119","university_rating":"1","sop":"4.02","lor":"3.6","cgpa":"7.06","research":"0","admission_points":"90"}, {"serial_no":"480","gre_score":"325","toefl_score":"110","university_rating":"1","sop":"2.9","lor":"4","cgpa":"3.7","research":"0","admission_points":"79"},{"serial_no":"316","gre_score":"308","toefl_score":"104","university_rating":"5","sop":"1.6","lor":"3","cgpa":"9.45","research":"1","admission_points":"65"},{"serial_no":"182","gre_score":"305","toefl_score":"107","university_rating":"4","sop":"2.5","lor":"2.5","cgpa":"4.65","research":"0","admission_points":"71"},{"serial_no":"171","gre_score":"312","toefl_score":"91","university_rating":"5","sop":"2.5","lor":"3.5","cgpa":"8.47","research":"1","admission_points":"68"}]
```

Output:

```
{
    "results": {
        "0": {
            "0": 49.48327255766584,
            "1": 31.746300469670317,
            "2": 90.29413245866955,
            "3": 50.52227582039556,
            "4": 86.02847856649437
        }
    }
}
```



En esta ejecución es interesante resaltar la diferencia que causó interferir en los valores de los features más importantes, lo que causó una predicción muy distinta a lo que se esperaba.

En la siguiente tabla podemos ver real vs predicha:

Real	Predicción
90	49.48
79	31.74
65	90.29
71	50.52
68	86.02

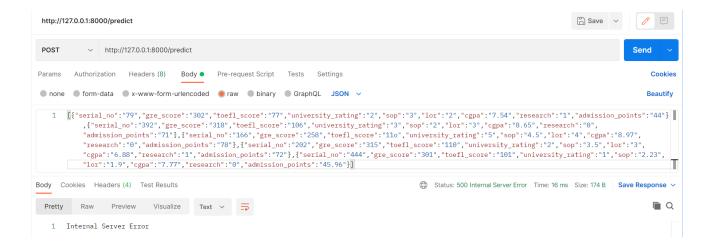
Escenario 5.

En este escenario provocaremos una ejecución fallida. Para eso, tomaremos 5 elementos del dataset original pero modificaremos uno agregándole un carácter a una de sus columnas, lo que hará que el modelo falle ya que debe recibir solo valores numéricos.

```
[{"serial_no":"79","gre_score":"302","toefl_score":"77","university_rating":"2",
"sop":"3","lor":"2","cgpa":"7.54","research":"1","admission_points":"44"},{"seri
al_no":"392","gre_score":"318","toefl_score":"106","university_rating":"3","sop"
:"2","lor":"3","cgpa":"8.65","research":"0","admission_points":"71"},{"serial_no
":"166","gre_score":"258","toefl_score":"110","university_rating":"5","sop":"4.5
","lor":"4","cgpa":"8.97","research":"0","admission_points":"78"},{"serial_no":"
202","gre_score":"315","toefl_score":"110","university_rating":"2","sop":"3.5","
lor":"3","cgpa":"6.88","research":"1","admission_points":"72"},{"serial_no":"444
","gre_score":"301","toefl_score":"101","university_rating":"1","sop":"2.23","lo
r":"1.9","cgpa":"7.77","research":"0","admission_points":"45.96"}]
```

Output:

Internal Server Error



Mensaje de error recibido en consola del servicio:

```
File "C:\Users\danie\Desktop\Escritorio\Universidad\202220\BI\Lab4\Lab4\.\main.py
 line 31, in make_predictions
   dataModels = [json.loads(json.dumps(data), object_hook=lambda d: DataModel(**d))
for data in list_dataModel]
 File "C:\Users\danie\Desktop\Escritorio\Universidad\202220\BI\Lab4\Lab4\.\main.py"
 line 31, in <listcomp>
   dataModels = [json.loads(json.dumps(data), object_hook=lambda d: DataModel(**d))
for data in list_dataModel]
 File "C:\Users\danie\AppData\Local\Programs\Python\Python310\lib\json\_init_.py"
 line 359, in loads
   return cls(**kw).decode(s)
 File "C:\Users\danie\AppData\Local\Programs\Python\Python310\lib\json\decoder.py"
line 337, in decode
   obj, end = self.raw_decode(s, idx=_w(s, 0).end())
 File "C:\Users\danie\AppData\Local\Programs\Python\Python310\lib\json\decoder.py",
line 353, in raw_decode
   obj, end = self.scan_once(s, idx)
 File "C:\Users\danie\Desktop\Escritorio\Universidad\202220\BI\Lab4\Lab4\.\main.py'
 line 31, in <lambda>
   dataModels = [json.loads(json.dumps(data), object_hook=lambda d: DataModel(**d))
for data in list_dataModel]
 File "pydantic\main.py", line 342, in pydantic.main.BaseModel._
pydantic.error wrappers.ValidationError: 1 validation error for DataModel
toefl score
 value is not a valid float (type=type_error.float)
```

El mensaje es recibido ya que en el DataModel no se aceptan datos de tipo String. Por ejemplo, la columna que lanzó excepción fue toefl_score, que está declarada en el DataModel como float.

Segundo endpoint - Retraining:

En esta sección vamos a probar 5 escenarios distintos, donde variará la cantidad de muestras para entrenar al modelo y la variable objetivo. Debido a que varios de los

escenarios presentan una gran cantidad de muestras para entrenar el modelo, sólamente mostraremos en el documento el primero como forma de dar a entender el formato que siguen los JSON para el re-entrenamiento.

Escenario 6.

Número de muestras: 10 muestras. Variable objetivo: Admission Points

```
{"Serial
No.":{"0":479,"1":446,"2":336,"3":20,"4":432,"5":112,"6":55,"7":59,"8":123,"9":4
"GRE
Score":{"0":327,"1":301,"2":297,"3":303,"4":320,"5":321,"6":306,"7":299,"8":311,
"9":298},
"TOEFL
Score":{"0":113,"1":92,"2":100,"3":98,"4":94,"5":84,"6":110,"7":112,"8":74,"9":9
8},
"University
Rating":{"0":4,"1":1,"2":1,"3":3,"4":2,"5":4,"6":3,"7":1,"8":4,"9":2},
"SOP":{"0":4.0,"1":1.85,"2":2.41,"3":3.5,"4":1.38,"5":4.13,"6":3.0,"7":0.97,"8":
1.5, "9": 2.23},
"LOR
":{"0":2.77,"1":1.5,"2":1.59,"3":3.0,"4":3.5,"5":4.0,"6":3.5,"7":2.0,"8":0.53,"9
":3.73},
"CGPA":{"0":8.88,"1":7.71,"2":7.89,"3":8.5,"4":8.78,"5":8.68,"6":8.0,"7":6.82,"8
":8.36, "9":7.43},
"Research":{"0":1,"1":0,"2":0,"3":0,"4":1,"5":1,"6":0,"7":1,"8":0,"9":0},
"Admission
Points":{"0":84.47,"1":45.08,"2":47.42,"3":62.0,"4":73.0,"5":69.0,"6":70.0,"7":4
0.03, "8": 57.0, "9": 49.08},
"var_obj":"Admission Points"
}
```

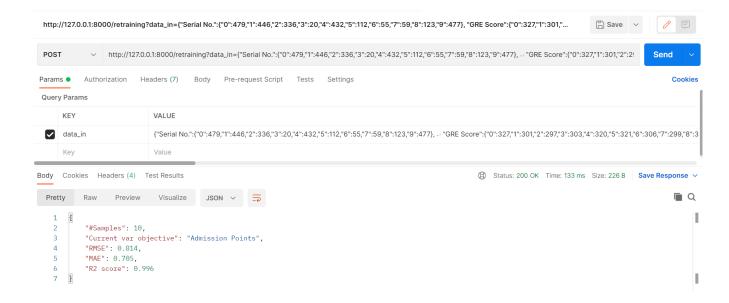
Como podemos evidenciar, las muestras se colocan consecutivamente según la columna y finalmente tenemos un atributo var_obj que describe cuál de las columnas será la variable objetivo.

Output:

```
{
   "#Samples": 10,
   "Current var objective": "Admission Points",
   "RMSE": 0.814,
   "MAE": 0.705,
   "R2 score": 0.996
```

}

Ejecución en Postman:



Escenario 7.

Número de muestras: 500 muestras. Variable objetivo: Admission Points

Output:

```
{
    "#Samples": 500,
    "Current var objective": "Admission Points",
    "RMSE": 106.171,
    "MAE": 7.586,
    "R2 score": 0.721
}
```

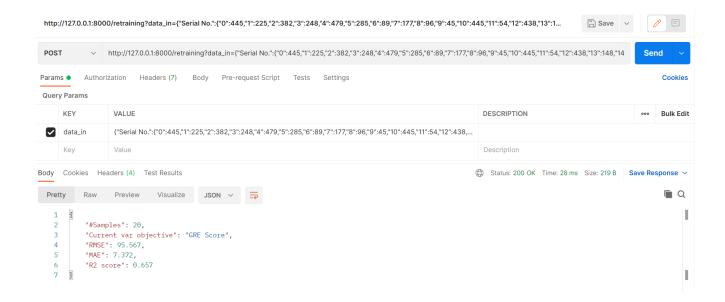


Escenario 8.

Número de muestras: 20 muestras. Variable objetivo: GRE Score

Output:

```
{
    "#Samples": 20,
    "Current var objective": "GRE Score",
    "RMSE": 95.567,
    "MAE": 7.372,
    "R2 score": 0.657
}
```



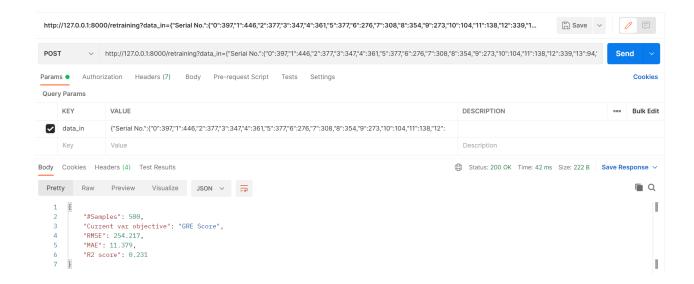
Escenario 9.

Número de muestras: 500 muestras.

Variable objetivo: GRE Score

Output:

```
{
    "#Samples": 500,
    "Current var objective": "GRE Score",
    "RMSE": 254.217,
    "MAE": 11.379,
    "R2 score": 0.231
}
```



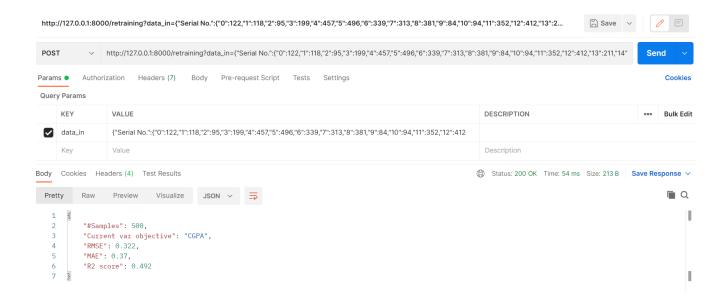
Escenario 10.

Número de muestras: 500 muestras.

Variable objetivo: CGPA

Output:

```
{
    "#Samples": 500,
    "Current var objective": "CGPA",
    "RMSE": 0.322,
    "MAE": 0.37,
    "R2 score": 0.492
}
```



Conclusiones:

Los resultados obtenidos son relevantes por que nos permiten darnos cuenta de los siguientes factores:

- En los escenarios de predicción donde se ingresaron las muestras reales pudimos obtener resultados satisfactorios. Donde si bien existían casos en los que la predicción se podía alejar un poco del valor real, el modelo hacía un buen trabajo prediciendo los valores de forma óptima de varias pruebas realizadas.
- El modelo es susceptible a errores siempre sucedan uno de los siguientes escenarios:

En primer lugar, los valores de los features con mayor correlación sean muy desproporcionados o por poco sentido, lo que puede influir en una mala predicción por parte del modelo.

En segundo lugar, como pudimos evidenciar, cuando se ingresa un tipo de dato incorrecto al modelo ocasiona que este tenga un fallo directamente en el programa, lo que detiene su ejecución. Es por eso que es importante que se pueda asegurar la calidad de los datos si se lleva a un ambiente de producción donde deba realizar predicciones de forma regular y no se quiere que el modelo deje de funcionar por una ejecución fallida.

• El segundo endpoint de reentrenamiento nos permite que el modelo pueda volver a ser entrenado durante su montaje en ejecución, lo que significa que no sólo un científico de datos o programar puede hacer dicha tarea, sino que sus

usuarios finales pueden realizar esa tarea de forma sencilla pasándole un dataset al modelo por medio del API así este se puede reentrenar.

Finalmente, para mitigar incoherencias en la predicción y errores de ejecución es importante que si el API es conectado a otro servicio que le provea los datos, tales como un frontend, se asegure desde ese servicio la calidad de los datos. Es decir, que los datos que se ingresan sean coherentes y reales, y para asegurar su correcta ejecución, que los datos respeten su dominio (por ejemplo *University Ranking* debe ser entre 1 y 5) y que los datos sean numéricos sin contener ningún tipo de carácter.